BETALYTIX

Takım Performansına Dayalı Futbol Maç Sonucu Tahmin Sistemi

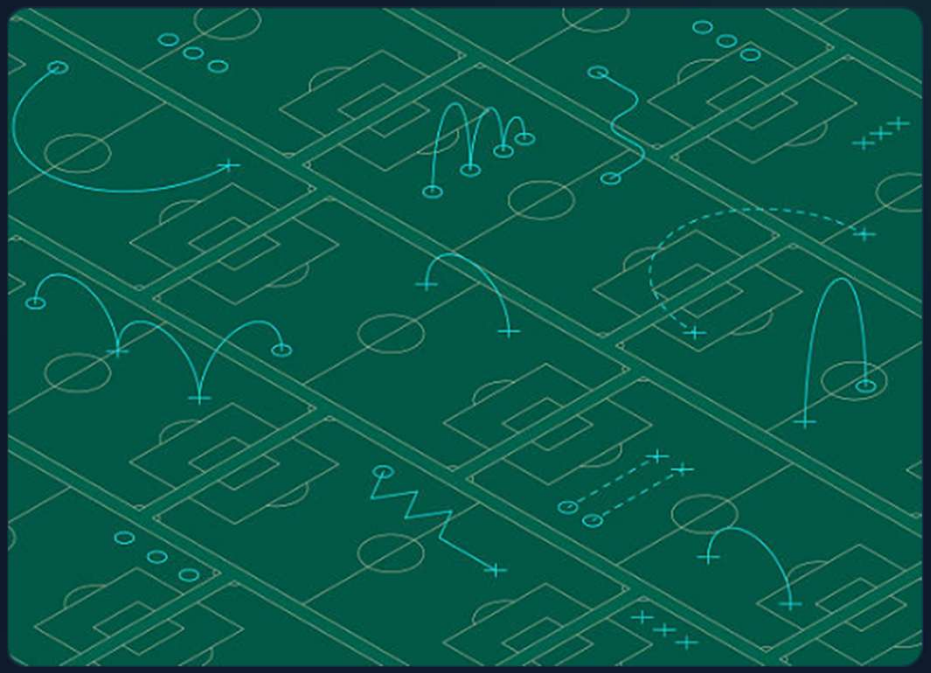
Proje Sahibi: Efe Örencik

SQL · Python · Scikit-learn · XGBoost · Streamlit

Problem Tanımı: Çözmeye Çalıştığım Sorun Neydi?

Temel Soru

Bir sonraki maçın sonucunu (Ev Sahibi / Beraberlik / Deplasman), geçmiş takım performans verisine dayanarak — piyasa (bahis) bilgisi kullanmadan — ne kadar isabetli tahmin edebiliriz?



Neden Önemli?

- Salt piyasa oranını kopyalamak yerine gerçek bir tahmin yetkinliği inşa eder.
- Veri mühendisliği + modelleme + ürünleştirme sürecini uçtan uca deneyimletir.
- Portföyde gösterilebilir, çalışan bir teknik ürün ortaya koyar.

PROBLEM

Maç sonucu belirsizliği, veriye dayalı azaltılabilir mi?

KULLANICI

Analitik karar desteği arayan son kullanıcılar

HEDEF DEĞİŞKEN

MS1 – X – MS2
(3 Sınıflı Sınıflandırma)

Kullanılan Araçlar ve Teknolojiler

Projenin veri tabanından son kullanıcı arayüzüne kadar olan sürecinde modern veri bilimi kütüphaneleri kullanıldı.



SQL

Veri Toplama & Keşif

Ham veri setinin filtrelenmesi, yapısal bütünlüğünün kontrolü ve ön keşif (EDA) aşamalarında kullanıldı.



Python & Pandas

Veri İşleme

Kronolojik sıralama, veri temizliği ve istatistiksel feature engineering (özellik mühendisliği) süreçlerinin tamamı yürütüldü.



Scikit-learn & XGBoost

Makine Öğrenmesi

Baseline modeller (Logistic Regression, Random Forest) kuruldu ve final tahmin algoritması olarak XGBoost hiperparametre optimizasyonu ile eğitildi.



Streamlit

Ürünleştirme

Geliştirilen modellerin son kullanıcı tarafından test edilebilmesi için interaktif bir web dashboard'una entegre edildi.

Hangi Metodları Kullandım? — Uçtan Uca Pipeline

Veriden ürüne giden yolda 7 fazlı, kontrol noktalı sıralı geliştirme metodolojisi izlendi.

01	02	03	04	05	06	07
Veri Anlama	Temizleme	Feature Eng.	Baseline Model	Gelişmiş Model	İş Yorumu	Ürünleştirme
SQL ile keşif	Tarih, tip, kronoloji	20+ değişken üretimi	Logistic + Random Forest	XGBoost Tuning	Model vs. piyasa	Streamlit demo

Temel Metodolojik Kurallar

- **Katı Kronolojik Veri Ayrımı:** Gelecekten geçmişe bilgi sızmasını (Data Leakage) önlemek için eğitim ve test ayrımı rastgele değil, katı zaman ekseninde yapıldı.
- **İzole Özellik Mühendisliği (Groupby-Shift):** Takımların form durumları hesaplanırken, sadece geçmiş maçlarına bakılması için özel pandas transformasyonları uygulandı.
- **Salt Performans Odağı:** Piyasada var olan hazır tahmin oranları girdi olarak kullanılmayarak, algoritmanın takımların salt hücum/savunma metriklerinden öğrenmesi zorunlu kılındı.

Feature Engineering (Özellik Mühendisliği)

Makine öğrenmesi modelinin tahminsel gücünü belirleyen 20'den fazla analitik değişken üretildi.

Form

- Son 3, 5 ve 10 maçlık hareketli ortalamalar
- Geçmiş maç puan ortalaması
- Atılan ve yenilen gol trendleri

Hücum / Savunma

- Şut & isabetli şut ortalamaları
- Attack / Defense Rating (Güç Endeksi)
- Clean sheet (Gol yemeden bitirme) oranı

Saha Avantajı

- Tarihsel iç saha galibiyet oranı
- Tarihsel deplasman galibiyet oranı
- Ev-Deplasman formu ve gol farkları

İleri Seviye

- Dominance Score (Oyun Hakimiyeti Puanı)
- Temporal Decay (Eski maçların etkisini azaltma)
- Form ve Hücum güçlerinin birbirine oranı

Feature Selection (Değişken Seçimi) Etkisi

Üretilen tüm değişkenler doğrudan modele verilmedi. Korelasyon analizleri ve "Feature Importance" (Değişken Önem Derecesi) testleri yapılarak en yüksek sinyali veren **Top-20** değişken belirlendi, bu sayede "Noise" (Gürültü) engellendi.

Analiz ve Model Sonuçları

Aynı optimize edilmiş veri seti (Top-20 Feature) kullanılarak eğitilen modellerin test verisi üzerindeki performansı.



Model Algoritması	Accuracy (Doğruluk)	F1 Score (Macro)
Logistic Regression	0.536	0.44
Random Forest	0.533	0.42
XGBoost	**0.562**	**0.46**

Not: Hedef değişken 3 sınıflı (Kazanma, Kaybetme, Beraberlik) olduğu için rastgele tahmin başarısı %33.3'tür. Modelimiz bu oranı %56.2'ye taşımıştır.

Sonuç Yorumu

- Basit ve doğrusal yaklaşım olan Logistic Regression güçlü bir temel oluşturdu.
- Ağaç bazlı yöntemlerden Random Forest aşırı öğrenmeye (overfitting) daha yatkın olduğu için test setinde beklenen sıçramayı yapamadı.
- **XGBoost**, gradient boosting yapısı sayesinde doğrusal olmayan kompleks takım etkileşimlerini yakalayarak genelleme başarısında lider oldu.

Gerçek Maç Örneği: Galatasaray vs. Fenerbahçe

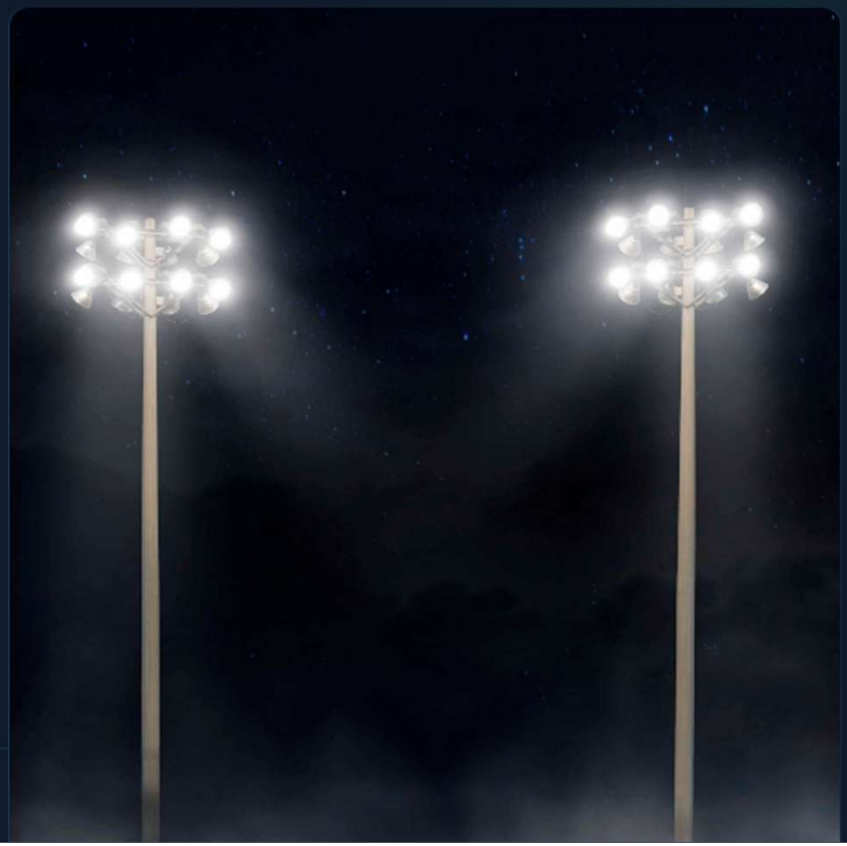
Modelin ürettiği olasılıkların, piyasa algısı ile karşılaştırılarak "Değerli Bahis" (Value Bet) tespiti.

%58

Modelin GS Galibiyeti Olasılığı

%49

Piyasanın Tahmin Ettiği Olasılık



Olasılık Dağılımı	Galatasaray (MS1)	Beraberlik (X)	Fenerbahçe (MS2)
XGBoost Modeli	**%58**	%20	%22
Piyasa Analizi	%49	%25	%26
Fark (Value)	**+9 Puan**	-5 Puan	-4 Puan

BETALYTIX | Maç Sonucu Tahmin Sistemi

Analitik İçgörü

Demo Uygulama — Streamlit Dashboard

Modellerin test edilmesi ve sonuçların görselleştirilmesi için geliştirilen interaktif web arayüzü.

Tahmin Modülü

- Kullanıcı tarafından canlı takım seçimi
- Algoritma seçimi (LR, RF, XGBoost)
- Olasılıkların dinamik hesaplanması

Metrik ve Rapor

- Model başarı metriklerinin tablosu
- Sınıf bazlı model doğruluk grafiği
- XGBoost Feature Importance analizi

Takım Verileri

- Takımların anlık form grafikleri
- Son 5 maçlık hücum istatistikleri
- Ev sahibi / deplasman avantaj durumu



```
$ streamlit run app/app.py
```

Uygulama yerelde çalışmaya hazır yapıdadır.

Riskler ve Kısıtlar

Modelin gerçek hayattaki güvenilirliğini etkileyebilecek kısıtlar ve dikkat edilmesi gereken noktalar.

Yüksek	Sakatlık ve Kadro Bilgisi Eksikliği	Model sadece geçmiş takım verisine bakar; yıldız bir oyuncunun sakatlığını model bilemez.
Orta	Ligler Arası Dinamik Farkları	Farklı liglerin form ve güç dinamikleri normalize edilmeden tek bir modele dahil edilmemelidir.
Orta	Sezon Başı Belirsizliği (Cold Start)	Sezonun ilk haftalarında, takımların henüz yeterli geçmiş verisi (formu) oluşmadığı için hata payı yüksektir.
Düşük	Veri Güncelliği İhtiyacı	Futbol değişken bir oyundur; modelin kalitesini korumak için haftalık bazda yeniden eğitilmesi (retrain) gerekir.

Sonraki Adımlar ve Proje Teslimleri

Tamamlanan Teslimler

- Veri tabanı şemaları ve temizleme (SQL) scriptleri
- Veri Keşfi (EDA) ve analiz Jupyter notebook'ları
- Makine öğrenmesi pipeline ve modelleme kodları
- Model performans metriklerini içeren değerlendirme raporu
- Açık kaynak Github deposu ve yerel Streamlit uygulaması

Planlanan Geliştirmeler (V2)

- Oyuncu istatistikleri ve sakatlık verilerinin (Web Scraping ile) entegrasyonu
- Tahmin kapsamını Alt/Üst ve KG Var/Yok şeklinde genişletmek
- Modellerin bulut ortamına (AWS/GCP) API olarak aktarımı (Deployment)
- Canlı veri beslemesi sağlayan otomatik pipeline yapısı kurmak

Kazanılan Yetkinlik Özeti

SQL ile Veri Manipülasyonu	Kapsamlı Feature Engineering	Algoritma Karşılaştırması
XGBoost Hiperparametre Optimizasyonu	Data Leakage Tespit & Çözümü	Web Framework (Streamlit) ile Ürünleştirme

Teşekkürler

Sorular ve teknik değerlendirmeleriniz için hazırım.

orencikefe@gmail.com

BETALYTIX — Veri Bilimi Projesi